

数据仓库与数据挖掘

Data Warehouse and Data Mining

课程信息

- 网络学堂：课件、作业、通知
- 雨课堂：答题、签到
- 微信群



教师和助教联系方式


- 教师：宋韶旭

- Email: sxsong@tsinghua.edu.cn

- <https://sxsong.github.io>

- 助教：李松泽

- Email: lsz23@mails.tsinghua.edu.cn



课程目标

- 掌握数据仓库基本概念及原理
- 掌握数据挖掘的经典算法和原理
- 了解数据挖掘技术的应用及发展状况
- 具备相关领域科研及开发能力




Data Warehouse



Data Mining

参考教材

- Jiawei Han, Jian Pei and Hanghang Tong
- Data Mining: Concepts and Techniques
- 4th ed.



Chapter 1: Introduction

Chapter 2: Data, measurements, and data preprocessing

Chapter 3: Data warehousing and online analytical processing

Chapter 4: Pattern mining: basic concepts and methods

Chapter 5: Pattern mining: advanced methods

Chapter 6: Classification: basic concepts and methods

Chapter 7: Classification: advanced methods

Chapter 8: Cluster analysis: basic concepts and methods

Chapter 9: Cluster analysis: advanced methods

Chapter 10: Deep learning

Chapter 11: Outlier detection

Chapter 12: Data mining trends and research frontiers

课程内容

- 数据仓库：多维数据模型、OLAP分析、数据特征化
- 模式挖掘：关联规则挖掘、序列模式发现
- 数据分类：自动分类方法、数据不平衡问题、半监督及部分监督分类
- 聚类技术：聚类分析方法、数据稀疏、高维及海量数据聚类问题
- 异常检测：有监督与无监督方法、时序数据异常检测
- 复杂类型数据的挖掘、时序数据分析

教学安排

周次	内容
1	课程简介：绪论
2	数据仓库：多维数据模型、OLAP分析、数据特征化
3	放假停上
4	模式挖掘：关联规则挖掘、序列模式发现
5	数据分类：自动分类方法、数据不平衡问题、半监督及部分监督分类
6	聚类技术：聚类分析方法、数据稀疏、高维及海量数据聚类问题
7	异常检测：有监督与无监督方法、时序数据异常检测
8	课堂展示

考核要求

- 分组：每组4人，自由组队+助教分配，选择与每次课相关的主题
- 文献调研 30%
 - 文献阅读
 - KDD
 - ICDM
 - SDM
 - 汇报展示（每次课堂最后，相互打分）
 - Novelty
 - Strong points
 - Weak points



考核要求

■ 系统实现 70%

□ 系统平台

- 基于开源时序数据库Apache IoTDB的时序数据挖掘
- 挖掘算法作为UDF函数库算子进行实现

□ 算法内容

- 时序数据预测
- 时序数据异常检测
- 时序数据子序列聚类
- 时序数据分类
- 时序数据频繁模式挖掘

□ 课堂展示+学术报告（学期末）



数据仓库：多维数据模型、OLAP分析、数据特征化

预测技术：回归模型、树模型、网络模型，**时序**预测

数据分类：自动分类方法，数据不平衡问题、半监督及部分监督分类

聚类技术：聚类分析方法，数据稀疏、高维及海量数据聚类问题

异常检测：有监督与无监督方法，**时序**数据异常检测


关联分析：关联规则挖掘，**序列**模式发现

大作业说明


大作业说明

- 关注时间序列数据挖掘任务，并在IoTDB函数库中作为算子实现

- **预测任务**: to forecast a number of upcoming datapoints within a prediction window




- **分类/聚类任务**: to find the most homogeneous clusters that are as distinct as possible from other clusters, supervised or unsupervised




大作业说明

- 关注时间序列数据挖掘任务，并在IoTDB函数库中作为算子实现

- **异常检测任务**: to find abnormal points/ subsequences in a series



- **模式发现任务**: to find every subsequence (named motif) that appears recurrently in a longer time series



大作业说明

■ IoTDB函数库参考

- 开发文档 (<https://iotdb.apache.org/zh/UserGuide/latest/User-Manual/UDF-development.html>)
- 代码 (<https://github.com/apache/iotdb/tree/master/library-udf>)
- 现有函数库算子 (https://iotdb.apache.org/zh/UserGuide/latest/SQL-Manual/UDF-Libraries_apache.html)

■ 开源数据集参考

□ 预测任务

- Time Series Library Dataset (https://drive.google.com/drive/folders/1vE0ONyqPlym2JaaAoEe0XNDR8FS_d322)

□ 分类/聚类任务

- UCR Time Series Classification Archive (https://www.cs.ucr.edu/%7Eeamonn/time_series_data_2018/)

□ 异常检测任务

- Time Series Library Dataset (<https://drive.google.com/drive/folders/1KOQvV2nR6Y9tIkB4XELHA1CaV1F8LrZ6>)

□ 模式发现任务

- Time Series Library Dataset (https://drive.google.com/drive/folders/1vE0ONyqPlym2JaaAoEe0XNDR8FS_d322)

Apache IoTDB 基本工具安装

Java 安装 (Windows)

- 进入 Oracle JDK 官网，根据 Apache IoTDB 建议选择 JDK17 下载

Java SE subscribers have more choices

Also available for development, personal use, and to run other licensed Oracle products.

[GraalVM for JDK 17](#) has moved and is now available through [My Oracle Support \(MOS\)](#).

Java 17 **Java 11** **Java 8** **Java 8 Enterprise Performance Pack**

Java SE Development Kit 17.0.16 downloads

Java SE subscribers will receive JDK 17 updates until at least **September 2029**.

The Oracle JDK 17 license changed in October 2024

The [Oracle Technology Network License Agreement](#) for [Oracle Java SE](#) used for JDK 17 updates 17.0.13 and greater is substantially different from prior Oracle JDK 17 licenses. This license permits certain uses, such as personal use and development use, at no cost -- but other uses authorized under prior Oracle JDK licenses may no longer be available. Please review the terms carefully before downloading and using this product. FAQs are available [here](#).

Commercial license and support are available for a low cost with [Java SE Universal Subscription](#).


JDK 17.0.16 [checksums](#) and [OL 9 GPG Keys](#) for RPMs

Linux **macOS** **Windows**

Product/file description	File size	Download
x64 Compressed Archive	172.93 MB	jdk-17.0.16_windows-x64_bin.zip
x64 Installer	154.10 MB	jdk-17.0.16_windows-x64_bin.exe
x64 MSI Installer	152.85 MB	jdk-17.0.16_windows-x64_bin.msi

Java 安装 (Windows)

■ 添加系统变量与环境变量



Java 安装 (MacOS)

- 采用 Homebrew 安装
- 或进入 Oracle JDK 官网，选择 JDK17 下载并安装

Java 17 Java 11 Java 8 Java 8 Enterprise Performance Pack

Java SE Development Kit 17.0.16 downloads

Java SE subscribers will receive JDK 17 updates until at least **September 2029**.

The Oracle JDK 17 license changed in October 2024

The [Oracle Technology Network License Agreement for Oracle Java SE](#) used for JDK 17 updates 17.0.13 and greater is substantially different from prior Oracle JDK 17 licenses. This license permits certain uses, such as personal use and development use, at no cost -- but other uses authorized under prior Oracle JDK licenses may no longer be available. Please review the terms carefully before downloading and using this product. FAQs are available [here](#).

Commercial license and support are available for a low cost with [Java SE Universal Subscription](#).

JDK 17.0.16 [checksums](#) and [OL 9 GPG Keys](#) for RPMs

Linux **macOS** Windows

Product/file description	File size	Download
ARM64 Compressed Archive	168.10 MB	jdk-17.0.16_macos-aarch64_bin.tar.gz
ARM64 DMG Installer	167.51 MB	jdk-17.0.16_macos-aarch64_bin.dmg
x64 Compressed Archive	170.02 MB	jdk-17.0.16_macos-x64_bin.tar.gz
x64 DMG Installer	169.43 MB	jdk-17.0.16_macos-x64_bin.dmg

Java 安装检查

- 在终端中输入：
 - `java -version`
- 出现以下命令即为安装正确

```
C:\Users\jsxzp>java -version
java version "17.0.16" 2025-07-15 LTS
Java(TM) SE Runtime Environment (build 17.0.16+12-LTS-247)
Java HotSpot(TM) 64-Bit Server VM (build 17.0.16+12-LTS-247, mixed mode, sharing)
```

- 若出现安装问题，可以检查环境变量是否配置完成（包括 MacOS）

Maven 安装 (Windows)

■ 进入 Maven 官网，选择新版 Maven 下载



Apache / Maven / Download Apache Maven  [Download](#) | [Get Sources](#) | Last Published: 2025-09-20

Welcome

License

ABOUT MAVEN

What is Maven?

Installation

Downloads

Use

Run

Configure

Release Notes

DOCUMENTATION

Maven Plugins

Maven Extensions

Maven Tools

Maven Daemon

Maven Upgrade Tool

Index (category)

User Centre

Plugin Developer Centre

Maven Repository Centre

Maven Developer Centre

Books and Resources

Security

COMMUNITY

Community Overview

Project Roles

Downloading Apache Maven 3.9.11

Apache Maven 3.9.11 is the latest release: it is the recommended version for all users.

System Requirements

Java Development Kit (JDK)	Maven 3.9+ requires JDK 8 or above to execute. It still allows you to build against 1.3 and other JDK versions by using toolchains .
Memory	No minimum requirement
Disk	Approximately 10MB is required for the Maven installation itself. In addition to that, disk space will be used for your local Maven repository. The size of your local repository will vary depending on usage but expect at least 500MB.
Operating System	No minimum requirement. Start up scripts are included as shell scripts (tested on many Unix flavors) and Windows batch files.

Files

Maven is distributed in several formats for your convenience. Simply pick a ready-made binary distribution archive and follow the [installation instructions](#). Use a source archive if you intend to build Maven yourself.


In order to guard against corrupted downloads/installations, it is highly recommended to [verify the signature](#) of the release bundles against the public [KEYS](#) used by the Apache Maven developers.

	Link	Checksums	Signature
Binary tar.gz archive	apache-maven-3.9.11-bin.tar.gz	apache-maven-3.9.11-bin.tar.gz.sha512	apache-maven-3.9.11-bin.tar.gz.asc
Binary zip archive	apache-maven-3.9.11-bin.zip Windows	apache-maven-3.9.11-bin.zip.sha512	apache-maven-3.9.11-bin.zip.asc
Source tar.gz archive	apache-maven-3.9.11-src.tar.gz	apache-maven-3.9.11-src.tar.gz.sha512	apache-maven-3.9.11-src.tar.gz.asc
Source zip archive	apache-maven-3.9.11-src.zip	apache-maven-3.9.11-src.zip.sha512	apache-maven-3.9.11-src.zip.asc

- 3.9.11 [Release Notes](#) and [Release Reference Documentation](#)
- [latest source code from source repository](#)
- Distributed under the [Apache License](#), version 2.0
- other:
 - All current release sources (plugins, shared libraries,...) available at <https://downloads.apache.org/maven/>

Maven 安装 (Windows)

■ 添加系统变量与环境变量



Maven 安装 (MacOS)

- 采用 Homebrew 直接安装
- 或进入 Maven 官网，选择新版 Maven 下载并解压



Apache / Maven / Download Apache Maven

Download | Get Sources | Last Published: 2025-09-20

Welcome

License

ABOUT MAVEN

What is Maven?

Installation

Downloads

Use

Run

Configure

Release Notes

DOCUMENTATION

Maven Plugins

Maven Extensions

Maven Tools

Maven Daemon

Maven Upgrade Tool

Index (category)

User Centre

Plugin Developer Centre

Maven Repository Centre

Maven Developer Centre

Books and Resources

Security

COMMUNITY

Community Overview

Project Roles

Downloading Apache Maven 3.9.11

Apache Maven 3.9.11 is the latest release: it is the recommended version for all users.

System Requirements

Java Development Kit (JDK)	Maven 3.9+ requires JDK 8 or above to execute. It still allows you to build against 1.3 and other JDK versions by using toolchains .
Memory	No minimum requirement
Disk	Approximately 10MB is required for the Maven installation itself. In addition to that, disk space will be used for your local Maven repository. The size of your local repository will vary depending on usage but expect at least 500MB.
Operating System	No minimum requirement. Start up scripts are included as shell scripts (tested on many Unix flavors) and Windows batch files.

Files

Maven is distributed in several formats for your convenience. Simply pick a ready-made binary distribution archive and follow the [installation instructions](#). Use a source archive if you intend to build Maven yourself.

In order to guard against corrupted downloads/installations, it is highly recommended to [verify the signature](#) of the release bundles against the public [KEYS](#) used by the Apache Maven developers.

	Link	Checksums	Signature
Binary tar.gz archive	apache-maven-3.9.11-bin.tar.gz MacOS	apache-maven-3.9.11-bin.tar.gz.sha512	apache-maven-3.9.11-bin.tar.gz.asc
Binary zip archive	apache-maven-3.9.11-bin.zip	apache-maven-3.9.11-bin.zip.sha512	apache-maven-3.9.11-bin.zip.asc
Source tar.gz archive	apache-maven-3.9.11-src.tar.gz	apache-maven-3.9.11-src.tar.gz.sha512	apache-maven-3.9.11-src.tar.gz.asc
Source zip archive	apache-maven-3.9.11-src.zip	apache-maven-3.9.11-src.zip.sha512	apache-maven-3.9.11-src.zip.asc

- 3.9.11 Release Notes and Release Reference Documentation
- latest source code from source repository
- Distributed under the Apache License, version 2.0
- other:
 - All current release sources (plugins, shared libraries,...) available at <https://downloads.apache.org/maven/>

Maven 安装 (MacOS)

- 确定当前使用的终端:

- `echo $SHELL` # 若输出 `/bin/zsh`, 则使用 `zsh`; 若输出 `/bin/bash`, 则使用 `bash`。

- 打开配置文件

- `open ~/.zshrc` # `bash`用户替换为对应的`.bash_profile`或`.bashrc`

- 在结尾添加:

- `export MAVEN_HOME=/path/to/maven`

- `export PATH=$MAVEN_HOME/bin:$PATH`

- 配置文件立即生效:

- `source ~/.zshrc`

Maven 安装检查

- 在终端中输入：
 - mvn -v
- 出现以下命令即为安装正确

```
C:\Users\jsxzp>mvn -v
Apache Maven 3.9.11 (3e54c93a704957b63ee3494413a2b544fd3d825b)
Maven home: D:\Maven\apache-maven-3.9.11
Java version: 17.0.16, vendor: Oracle Corporation, runtime: D:\JavaJDK\jdk-17
Default locale: zh_CN, platform encoding: GBK
OS name: "windows 11", version: "10.0", arch: "amd64", family: "windows"
```


Apache IoTDB 下载、编译及部署

Apache IoTDB 下载

■ 采用 Git clone, 或从官网下载源码

□ `git clone -b master https://github.com/apache/iotdb.git`

□ 官网:



发行版本

2023年7月10日 大约 12 分钟

此页内容 >

版本	IoTDB 二进制包			IoTDB 源代码			发布说明
2.0.5	All-in-one	SHA512	ASC	源代码	SHA512	ASC	release notes
	AI Node	SHA512	ASC				
1.3.5	All-in-one	SHA512	ASC	源代码	SHA512	ASC	release notes
	AI Node	SHA512	ASC				
0.13.4	All-in-one	SHA512	ASC	源代码	SHA512	ASC	release notes
	Grafana 连接器	SHA512	ASC				
	Grafana 插件	SHA512	ASC				

历史版本下载: <https://archive.apache.org/dist/iotdb/>

Apache IoTDB 编译

- 在 IoTDB 根目录下执行:

- mvn clean package -pl distribution -am -DskipTests

- 编译结果目录结构:

- distribution
 - \---target
 - +---apache-iotdb-2.0.5-all-bin
 - | \---apache-iotdb-2.0.5-all-bin
 - | +---sbin
 - | | \---windows
 - | | start-standalone.bat
 - | | stop-standalone.bat
 - | |

Apache IoTDB 部署

■ 运行一个 1C1D 的 IoTDB:

- 进入对应目录后运行:

- `> sbin/start-standalone.sh` # Unix/OS X

- `> sbin\windows\start-standalone.bat` # Windows

- 或通过运行 `start-confignode` / `start-datanode` 等单独启动 `confignode` 与 `datanode`
 - 在运行命令后添加 `'-d'` 参数, 可以后台启动节点

■ 启动 IoTDB 客户端:

- 进入对应目录后运行:

- `> sbin/start-cli.sh -h 127.0.0.1 -p 6667 -u root -pw root` # Unix/OS X

- `> sbin\windows\start-cli.bat -h 127.0.0.1 -p 6667 -u root -pw root` # Windows

Apache IoTDB UDF 开发

用户定义函数 UDF

■ 用户定义函数 User-Defined Function (UDF)

- 目标：用户**自定义功能模块**，实现代码复用
- 以成绩判断为例子：

```
def UserDefinedFunction(x):  
    return x;
```

Python

自定义函数：根据分数返回等级

```
def get_grade(score):  
    if score >= 90:  
        return "A"  
    elif score >= 60:  
        return "B"  
    else:  
        return "C"
```

调用

```
print(get_grade(85))
```

Python 中



```
CREATE FUNCTION GetScoreLevel(score INT)  
RETURNS CHAR(1)  
BEGIN  
    IF score >= 90 THEN RETURN 'A';  
    ELSEIF score >= 60 THEN RETURN 'B';  
    ELSE RETURN 'C';  
    END IF;  
END;
```

-- 调用

```
SELECT name, score, GetScoreLevel(score) FROM student;
```

数据库中

IoTDB UDF

- IoTDB 提供多种内建的面向时序处理的函数，也支持扩展自定义函数来满足更多的计算需求
- IoTDB 支持两种类型的 UDF 函数：表 / 聚合

UDF 分类	数据访问策略	描述
UDTF	MAPPABLE_ROW_BY_ROW	自定义 标量函数 ，输入 k 列时间序列 1 行数据，输出 1 列时间序列 1 行数据，可用于 标量函数出现的任何子句和表达式中 ，如select子句、where子句等。
	ROW_BY_ROW SLIDING_TIME_WINDOW SLIDING_SIZE_WINDOW SESSION_TIME_WINDOW STATE_WINDOW	自定义 时间序列生成函数 ，输入 k 列时间序列 m 行数据，输出 1 列时间序列 n 行数据，输入行数 m 可以与输出行数 n 不相同， 只能用于SELECT子句中 。
UDAF	-	自定义 聚合函数 ，输入 k 列时间序列 m 行数据，输出 1 列时间序列 1 行数据，可用于 聚合函数出现的任何子句和表达式中 ，如select子句、having子句等。

多行 → 多行

多行 → 一行

IoTDB UDF 使用

■ UDF 的使用方法与普通内建函数类似

□ 可以直接在 SELECT 语句中像调用普通函数一样使用UDF

- **基础SQL**语法: SLIMIT / SOFFSET, LIMIT / OFFSET, 值过滤, 时间过滤
- 带 * 的查询: **SELECT function(*) from root.sg.d1**
- 带**自定义输入参数**的查询: 向 UDF 传入任意数量的键值对参数。键值对中的键和值都需要被单引号或者双引号引起来。**注意, 键值对参数只能在所有时间序列后传入**

```
SELECT function(s1, 'key1'='value1', 'key2'='value2'), function(*, 'key3'='value3') FROM root.sg.d1;
```

```
SELECT function(s1, s2, 'key1'='value1', 'key2'='value2') FROM root.sg.d1;
```

- 与其他查询的**嵌套查询**

IoTDB UDF 管理

■ UDF 注册

- 实现一个完整的 UDF 类，假定这个类的全类名为org.apache.iotdb.udf.UDTFExample
- 将项目打成 JAR 包，可以使用Maven管理，具体可参照Example

[iotdb](#) / [example](#) / [udf](#) / [src](#) / [main](#) / [java](#) / [org](#) / [apache](#) / [iotdb](#) / [udf](#) /

Add file ▾

...



Cpaulyz Add TableFunctionHandle for TVF ✕

db3a384 · last year 🕒 History

Name	Last commit message	Last commit date
..		
table	Add TableFunctionHandle for TVF	last year
AggregateFunctionExample.java	Rename interface name of FunctionArguments	last year
ScalarFunctionExample.java	Rename interface name of FunctionArguments	last year
SlidingTimeWindowAccessStrategyExample.java	Fix sonar bugs and code smells in example (#10215)	3 years ago
UDAFExample.java	Fix WAL Exception catch & support new DataTypes in QueryDataSetUtils (#...	2 years ago
UDTFExample.java	Fix sonar bugs and code smells in example (#10215)	3 years ago

<https://github.com/apache/iotdb/tree/master/example/udf/src/main/java/org/apache/iotdb/udf>

IoTDB UDF 管理

■ UDF 注册

□ 使用以下 SQL 语句注册 UDF

```
CREATE FUNCTION <UDF-NAME> AS <UDF-CLASS-FULL-PATHNAME> (USING URI URI-STRING)
```

- 手动放置jar包：提前将 JAR 包放置到集群所有节点的 ext/udf 目录下

运行：

```
CREATE FUNCTION example AS 'org.apache.iotdb.udf.UDTFExample'
```

- 集群通过URI自动安装jar包：提前将 JAR 包上传到 URI 服务器上并确保执行注册语句的 IoTDB 实例能够访问该 URI 服务器

运行：

```
CREATE FUNCTION example AS 'org.apache.iotdb.udf.UDTFExample'  
USING URI 'http://jar/example.jar'
```

IoTDB UDF 管理

■ UDF 注册 注意事项

- 由于 IoTDB 的 UDF 是通过反射技术动态装载的，因此在装载过程中**无需启停服务器**
- UDF 函数名称是**大小写不敏感的**
- **不要**给 UDF 函数注册一个**内置函数的名字**，使用内置函数的名字给 UDF 注册会失败
- 不同的 JAR 包中最好不要有全类名相同但实现功能逻辑不一样的类。例如：
UDF(UDAF/UDTF)：udf1、udf2分别对应资源udf1.jar、udf2.jar。
如果两个 JAR 包里都包含一个org.apache.iotdb.udf.UDTFExample类，当同一个 SQL 中同时使用到这两个 UDF 时，系统会**随机加载其中一个类**，导致 UDF 执行行为不一致。

IoTDB UDF 管理

■ UDF 卸载

□ SQL: `DROP FUNCTION <UDF-NAME>`

■ 查看所有注册UDF

□ SQL: `SHOW FUNCTIONS`

■ UDF 配置:

□ 在 `iotdb-system.properties` 中配置 **udf 的存储目录**: 默认 `udf_lib_dir=ext/udf`

□ 提示内存不足时, 更改 `iotdb-system.properties` 中下述配置参数并重启服务:

- `udf_initial_byte_array_length_for_memory_control=48` (建议**略大于平均长度**)
- `udf_memory_budget_in_mb=30.0`
- `udf_reader_transformer_collector_memory_proportion=1:1:1` (读: 执行计算: 收集结果)

IoTDB UDF 函数库

- 目前 IoTDB 中提供了一系列关于时序数据处理的函数，包括数据质量、数据画像、异常检测、频域分析、数据匹配、数据修复、序列发现、机器学习
- 获取：<https://github.com/apache/iotdb/tree/rc/2.0.4/library-udf>
- 具体可以查看：
https://iotdb.apache.org/zh/UserGuide/latest/SQL-Manual/UDF-Libraries_apache.html
中对现有函数的介绍与实现，以及使用的示例

IoTDB UDF 开发

- 从 Maven 库 中搜索下面示例中的依赖: <https://search.maven.org>

```
<dependency>  
  <groupId>org.apache.iotdb</groupId>  
  <artifactId>udf-api</artifactId>  
  <version>1.0.0</version>  
  <scope>provided</scope>  
</dependency>
```

注意选择和目标 IoTDB 服务器版本相同的依赖版本

- 开发手册: https://iotdb.apache.org/zh/UserGuide/latest/User-Manual/User-defined-function_apache.html#_4-udf-开发

IoTDB UDF 开发与注册示例

- 可以通过完整编译的命令获取 jar 包：

- `mvn package -pl example/udf -am -DskipTests`

- 例如，在

- `/iotdb/example/udf/src/main/java/org/apache/iotdb/udf/UDTFExample.java`
路径下实现的UDF，执行上述命令编译后，会得到：

- `/iotdb/example/udf/target/udf-example-2.0.7-SNAPSHOT.jar`

- 之后，将该 jar 包移动至：

- `distribution/target/apache-iotdb-2.0.7-SNAPSHOT-all-bin/apache-iotdb-2.0.7-SNAPSHOT-all-bin/ext/udf/tmp`

- 在IoTDB中执行


- `CREATE FUNCTION example AS 'org.apache.iotdb.udf.UDTFExample'`

Apache IoTDB UDTF 介绍

IoTDB UDTF 开发: Overview

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类

- UDTF 实例生命周期



- <https://github.com/apache/iotdb/blob/master/example/udf/src/main/java/org/apache/iotdb/udf/UDTFExample.java> 中的例子

IoTDB UDTF 开发: beforeStart

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类
 - 至少实现**beforeStart方法**和一种**transform方法**
 - <https://github.com/apache/iotdb/blob/master/example/udf/src/main/java/org/apache/iotdb/udf/UDTFExample.java> 中的例子

```
@Override
public void beforeStart(UDFParameters parameters, UDTFConfigurations configurations) {
    configurations.setAccessStrategy(new RowByRowAccessStrategy()).setOutputDataType(Type.INT32);
}
```

- beforeStart: 初始化方法, 在 UDTF 处理输入数据前, 调用用户自定义的初始化行为
 - 帮助用户解析 SQL 语句中的 UDF 参数
 - 配置 UDF 运行时必要的信息 (UDF 访问原始数据时采取的策略和输出结果序列的类型)
 - 创建资源, 比如建立外部链接, 打开文件等

IoTDB UDTF 开发: beforeStart

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类
 - 至少实现**beforeStart方法**和一种**transform方法**
 - beforeStart方法具体实例


```
void beforeStart(UDFParameters parameters, UDTFConfigurations configurations) throws
Exception {
    String stringValue = parameters.getString("key1"); // iotdb
    Float floatValue = parameters.getFloat("key2"); // 123.45
    Double doubleValue = parameters.getDouble("key3"); // null
    int intValue = parameters.getIntOrDefault("key4", 678); // 678
    // do something

    // configurations
    // ...
}
```


```
SELECT UDF(s1, s2, 'key1'='iotdb', 'key2'='123.45') FROM root.sg.d;
```

IoTDB UDTF 开发: beforeStart

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类
 - 至少实现**beforeStart**方法和一种**transform**方法
 - beforeStart中输入策略:
 - MappableRowByRowStrategy 和 RowByRowAccessStrategy的构造不需要任何参数
 - **SlidingTimeWindowAccessStrategy**: 3个参数




窗口划分



参数修改

IoTDB UDTF 开发: beforeStart

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类
 - 至少实现**beforeStart方法**和一种**transform方法**
 - beforeStart中输入策略:
 - **SlidingSizeWindowAccessStrategy**: 2 个参数



IoTDB UDTF 开发: beforeStart


■ 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类

□ 至少实现**beforeStart**方法和一种**transform**方法

□ beforeStart中输入策略:

- SessionTimeWindowAccessStrategy: 2 个参数

时间间隔小于等于给定的最小时间间隔 sessionGap 则分为一组



IoTDB UDTF 开发: beforeStart


■ 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类

□ 至少实现**beforeStart**方法和一种**transform**方法

□ beforeStart中输入策略:

• **StateWindowAccessStrategy**: 2 个参数

数值型数据, 状态差值小于等于给定的阈值 delta 则分为一组



IoTDB UDTF 开发: validate

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类
 - 至少实现**beforeStart方法**和一种**transform方法**
 - <https://github.com/apache/iotdb/blob/master/example/udf/src/main/java/org/apache/iotdb/udf/UDTFExample.java> 中的例子

```
@Override
public void validate(UDFParameterValidator validator) throws Exception {
    validator
        // this udf only accepts 1 time series
        .validateInputSeriesNumber(1)
        // the data type of the first input time series should be INT32
        .validateInputSeriesDataType(0, Type.INT32)
        // this udf doesn't accept any extra parameters
        // the validation rule is not required because extra parameters will be ignored
        .validate(
            attributes -> ((Map) attributes).isEmpty(),
            "extra udf parameters are not allowed",
            validator.getParameters().getAttributes());
}
```

在初始化方法beforeStart调用前执行
检测用户输入的参数是否合法

IoTDB UDTF 开发: transform

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类
 - 至少实现**beforeStart**方法和一种**transform**方法
 - <https://github.com/apache/iotdb/blob/master/example/udf/src/main/java/org/apache/iotdb/udf/UDTFExample.java> 中的例子

```
@Override
public void beforeStart(UDFParameters parameters, UDTFConfigurations configurations) {
    configurations.setAccessStrategy(new RowByRowAccessStrategy()).setOutputDataType(Type.INT32);
}
```

```
@Override
public void transform(Row row, PointCollector collector) throws IOException {
    if (!row.isNull(0)) {
        collector.putInt(row.getTime(), -row.getInt(0));
    }
}
```

- transform: 由框架调用, 根据用户在 beforeStart 中对于策略的调整定义输入输出

IoTDB UDTF 开发: transform

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类
 - 至少实现**beforeStart方法**和一种**transform方法**
 - transform中输出对应:

setOutputDataType 中设定的输出类型	PointCollector 实际能够接收的输出类型
INT32	int
INT64	long
FLOAT	float
DOUBLE	double
BOOLEAN	boolean
TEXT	java.lang.String 和 org.apache.iotdb.udf.api.type.Binary

IoTDB UDTF 开发: terminate

- 编写UDTF 需要继承org.apache.iotdb.udf.api.UDTF类
 - 至少实现**beforeStart方法**和一种**transform方法**
 - terminate接口为UDF 需要**遍历完所有的原始数据后**才能得到输出结果的情况提供支持
 - 可以选择使用transform方法进行单纯的**数据处理**，最后使用terminate将处理**结果输出**
 - 在一次terminate方法调用中输出任意数量的数据点，但输出数据点的类型必须与beforeStart方法中设置的一致；结果需要由PointCollector输出

```
@Override
public void transform(Row row, PointCollector collector) {
    if (row.isNull(0)) {
        return;
    }
    int candidateValue = row.getInt(0);
    if (time == null || value < candidateValue) {
        time = row.getTime();
        value = candidateValue;
    }
}
```

```
@Override
public void terminate(PointCollector collector) throws IOException {
    if (time != null) {
        collector.putInt(time, value);
    }
}
```